

休闲零食连锁店商品销量预测

摘要

本文针对休闲零食连锁店商品销量预测问题，基于历史零售明细和天气、节假日、促销活动数据，构造日期-门店-商品粒度的日销量面板。数据清洗阶段确认销售数据覆盖 2020-04-01 至 2022-03-31，包含 7 家门店、12 个商品代码和 8 个商品类别；负销量按人工确认为损耗或冲销类负向调整，不作为正常购买需求，预测目标采用正向销量。

针对四个问题，本文采用可解释、可复现的分层建模路线。问题一使用移动平均、同星期均值和简单指数平滑分析门店、商品和门店-商品组合销量，门店层面以 7 日移动平均为主，商品和门店-商品层面以简单指数平滑为主，并补充 7 日窗口总量验证。问题二以附件类别字段作为同类零食的正式聚合依据，使用 Pearson、Spearman、去星期效应相关和门店内稳定性检查分析商品同步波动，类别预测采用“类别聚合后直接预测 + 简单指数平滑”。问题三以“合并天气 + 对数销量 + 历史控制固定效应回归”为主分析，描述性统计、温度分箱、去异常日、分门店/分类别稳健性和随机森林置换重要性作为辅助。问题四将历史销量、类别和外部变量纳入 Ridge 综合模型，并以严格 7 日递推验证作为主评价口径。

结果显示，问题一滚动验证下，门店层面移动平均 WAPE 为 37.49%，商品层面简单指数平滑 WAPE 为 38.14%，门店-商品层面简单指数平滑 WAPE 为 74.95%；补充的 7 日窗口总量验证中，原问题一主方案在商品层面 WAPE 为 21.51%，门店层面 WAPE 为 22.12%，门店-商品层面 WAPE 为 43.06%。问题二中，附件类别聚合后直接预测的 WAPE 为 34.74%，略优于单品预测后按类别加总的 34.83%。问题三中，合并天气、对数销量和历史控制固定效应回归的验证 WAPE 为 84.53%，优于原详细天气固定效应回归的 88.09%；活动日变量与销量上升之间呈现较稳定的统计关联，但本文不作因果解释。问题四严格 7 日递推验证下，问题一门店-商品简单指数平滑 WAPE 为 76.35%，综合 Ridge WAPE 为 76.68%，综合 Ridge 未超过强基准模型，但可作为融合前三问信息的综合解释模型。最终预测表 `outputs/final_7day_forecast.csv` 是在历史同期天气和活动日情景下得到的条件预测；若提交口径要求整数件数，使用 `outputs/final_7day_forecast_integer.csv`。

关键词：销量预测；移动平均；指数平滑；固定效应回归；严格递推验证；WAPE

1 问题重述

1.1 背景

休闲零食连锁门店需要根据历史销售数据安排订货、库存和促销活动。不同门店的客流基础不同，不同商品的销量规模和波动性也不同；同时，天气、节假日和门店活动可能与销售变化相关。因此，本题需要在理解历史销量结构的基础上，给出未来 7 天的销量预测，并分析商品关联和外部因素。

1.2 需要解决的问题

问题一要求分析不同门店和不同零食的销量情况，并分别预测未来 7 天总销量。该问题的输入是历史销售明细，输出包括门店层面、商品层面和门店-商品组合层面的预测结果。

问题二要求分析同一门店内不同零食销量之间的联系，整合同类零食，并预测未来 7 天总销量。该问题的关键是区分“商品销量同步波动”和“真实业务类别聚合”：相关性用于分析联系，附件类别字段用于正式类别预测。

问题三要求分析天气、节假日、活动日等因素与销量之间的关系。由于数据是观察数据而非随机实验，本文只讨论统计关联，不把外部变量写成严格因果影响。

问题四要求结合前三问模型和结论，预测各门店各种零食未来 7 天总销量，并与前序模型比较误差。该问题的关键是使用与未来 7 天预测一致的严格递推验证口径，避免把日滚动一步验证误写成未来 7 天一次性预测效果。

1.3 数据说明

附件一为历史零售明细，原始表含 67084 行、14 列，字段包括门店编号、门店名称、商品代码、商品名称、数量、销售额、收款时间和类别名称等。附件二为天气、节假日和促销活动数据，含 760 行、9 列，字段包括日期、天气、最高温、最低温、风力、节日、活动日和工休日等。字段说明见项目数据字典 DATA_DICTIONARY.md。

2 问题分析

本题的核心不是单一模型选择，而是按题目四问建立互相衔接的分析框架。问题一先建立可解释的销量基准模型，形成门店、商品和门店-商品三个粒度的基础预测；问题二在商品关联分析基础上进行类别聚合，解决同类零食整合预测；问题三分析外部变量与销量之间的条件统计关联，为综合模型提供特征解释；问题四在门店-商品粒度上融合历史销量、日历、类别和外部变量，并用严格 7 日递推验证检验其是否超过强基准模型。

预测评价不能随机切分，因为随机切分会让未来日期信息进入训练过程。本文使用时间顺序切分、日滚动验证和严格 7 日递推窗口验证。日滚动一步验证评价“每天更新真实销量后预测下一天”的能力；严格 7 日递推验证评价“窗口开始时一次性向未来预测 7 天”的能力，两者不能混用。

模型选择遵循三条原则：第一，所有结论来自附件数据或明确的模型计算；第二，优先使用本科数学建模竞赛中可解释、可复现、可写入论文的方法；第三，复杂模型只有在误差稳定下降且解释成本可控时才作为主方案。最终方法选择依据见 `outputs/method_search/final_method_selection.md`。

3 模型假设与符号说明

3.1 模型假设

1. 题目提供的销售明细和外部变量记录总体真实可靠。对于已发现的数据问题，本文采用记录、标记和统一口径处理，而不是直接删除原始数据。
2. 短期内历史销售规律具有一定延续性。未来 7 天预测依赖最近历史销量、同星期规律和类别/门店稳定差异。
3. 负销量不代表顾客正常购买需求。根据人工确认，负销量多对应破损、过期或冲销类负向调整，因此预测目标采用正向销量。
4. 附件类别字段可以作为同类零食的正式聚合依据。相关性聚类 and 销量规模分组只作为补充分析，不替代业务类别。
5. 天气、节假日和活动日与销量之间可以存在统计关联，但当前数据不足以识别严格因果效应。本文所称“影响因素分析”均指统计关联分析。
6. 未来 7 天无附件真实天气和真实活动安排。最终预测若使用天气和活动变量，应解释为“给定历史同期外部变量情景下”的条件预测。

3.2 符号说明

表 1: 主要符号说明

符号	含义
t	日期序号
s	门店编号
p	商品编号
g	商品类别
$y_{s,p,t}$	门店 s 、商品 p 在日期 t 的正向销量
$\hat{y}_{s,p,t}$	对 $y_{s,p,t}$ 的预测值
$Y_{t,g}$	日期 t 类别 g 的聚合销量
S_t	指数平滑中的平滑水平
α	指数平滑系数
r_{pq}	商品 p 与商品 q 的销量相关系数
X_t	日历、天气、活动日等外部变量
MAE	平均绝对误差
$RMSE$	均方根误差
$WAPE$	加权绝对百分比误差

4 数据预处理

4.1 数据检查

销售数据日期范围为 2020-04-01 至 2022-03-31，含 7 家门店、12 个商品代码、13 个商品名称和 8 个类别。商品代码 11001020 对应两个海苔商品名称，经人工确认以商品编号为准，名称差异视为录入笔误。天气数据日期范围为 2020-03-01 至 2022-03-30，不能覆盖销售最后一天 2022-03-31 和未来 2022-04-01 至 2022-04-07。

数据质量检查发现：销售明细中完全重复行 16605 条，经人工确认保留；负销量记录 54 条，作为损耗/冲销类负向调整；交易级数量范围为 -24 至 2712，IQR 规则标记 5536 条交易级极端记录。本文不删除原始记录，而是在处理表中保留正向销量、负向调整和异常标记。详细检查结果见 `outputs/stage1_data_inspection_report.md`。

4.2 日销量面板构造

本文将交易明细聚合为日期-门店-商品日销量面板，并补齐出现过的门店-商品组合在完整日期上的零销量记录。输出表 `data/processed/daily_store_product_sales.csv` 含 59130 行，日期范围为 2020-04-01 至 2022-03-31。合并外部变量后得到 `data/processed/modeling_base_table.csv`，同样为 59130 行。

日销量字段包括：

- `daily_sales`: 日净销量，包含负向调整；
- `positive_sales`: 正向销售数量，作为主预测目标；
- `negative_adjustment_qty`: 负向调整数量绝对值；
- `has_external_data`: 是否成功匹配附件二外部变量。

4.3 外部变量处理

附件二的“温度”和“温度.1”经人工确认为最高温和最低温，分别记为 `max_temperature` 和 `min_temperature`；“活动日”确认为门店促销活动日；“工休日”表示周末/节假日等休息日。缺少外部变量的销售日期为 2022-03-31，对应合并后 81 行 `has_external_data=0`。未来 7 天没有附件真实天气和活动日观测，本文在问题四中采用历史同期情景，并明确其条件预测性质。

5 问题一：门店与商品销量分析及未来 7 天预测

问题一以正向销量为目标，分别在门店、商品和门店-商品层级建模。设某一序列第 t 天销量为 y_t 。

5.1 模型建立

7 日移动平均模型为

$$\hat{y}_{t+1} = \frac{1}{7} \sum_{i=0}^6 y_{t-i}. \quad (1)$$

该模型用最近 7 天平均销量代表短期水平，适合作为门店层面的主模型。

同星期均值模型为

$$\hat{y}_t = \frac{1}{m} \sum_{j=1}^m y_{t-7j}, \quad m \leq 8. \quad (2)$$

该模型用历史相同星期几销量预测目标日，作为检验星期效应的基准模型。

简单指数平滑模型为

$$S_t = \alpha y_t + (1 - \alpha) S_{t-1}, \quad \hat{y}_{t+1} = S_t, \quad 0 < \alpha \leq 1. \quad (3)$$

该模型更重视近期销量，适合作为商品和门店-商品层面的主模型 [4]。

5.2 验证结果

阶段 2 日滚动验证结果见表 2。

表 2: 问题一日滚动验证下主模型误差

层级	主模型	MAE	RMSE	WAPE
门店	移动平均 (7 日)	9.685	15.445	37.49%
商品	简单指数平滑	5.748	10.968	38.14%
门店-商品	简单指数平滑	1.783	3.733	74.95%

为了使评价更贴近“未来 7 天总销量”，方法复核中补充 7 日窗口总量验证。结果显示，原问题一主方案在商品层面 WAPE=21.51%，门店层面 WAPE=22.12%，门店-商品层面 WAPE=43.06%。更复杂的滞后 Ridge 和随机森林未形成稳定优势，因此问题一保留原主模型。

5.3 描述性图表




图 1: 各门店累计销量，用于说明门店销量规模差异




图 2: 各商品累计销量，用于说明商品销量规模差异




图 3: 总体日销量趋势，用于观察历史销量波动




图 4: 星期效应，用于判断同星期均值模型是否有必要




图 5: 问题一模型 WAPE 对比，用于选择各层级主模型

5.4 问题一结果

历史累计销量最高的门店为 B 地江山店，累计销量 21773；历史累计销量最高的商品为红牛，累计销量 31119。门店和商品销量规模差异明显，说明不能只用统一平均水平预测所有对象。

未来 7 天门店预测中，B 地江山店预测总销量最高，为 309.0；C 地五乡镇店为 280.0；A 地天九街店为 245.0。商品预测中，乡吧哥蜜汁鸡翅预测 389.613，红牛预测 286.719，百事可乐 600ml 预测 136.219。问题一门店层面和商品层面分别建模，预测总量没有强制一致：门店层面合计 1296.000，商品层面合计 1226.006。

6 问题二：商品关联分析与类别聚合预测

问题二关注同一门店中不同零食销量之间的联系，并要求整合同类零食预测未来 7 天总销量。设 $y_{t,p}$ 表示第 t 天商品 p 的正向销量， $c(p)$ 表示商品所属类别。

6.1 商品销量矩阵与相关性

对每个门店构造日期 $\times$ 商品销量矩阵：

$$Y_s = (y_{t,p}), \quad t = 1, \dots, n, \quad p = 1, \dots, m. \quad (4)$$

商品 p 与商品 q 的 Pearson 相关系数为

$$r_{pq} = \frac{\sum_t (y_{t,p} - \bar{y}_p)(y_{t,q} - \bar{y}_q)}{\sqrt{\sum_t (y_{t,p} - \bar{y}_p)^2} \sqrt{\sum_t (y_{t,q} - \bar{y}_q)^2}}. \quad (5)$$

为避免单一 Pearson 相关造成过度解释，本文补充 Spearman 相关、去星期效应 Pearson 和门店内相关稳定性检查。商品关联结论只解释为同步波动，不写成果或替代关系。

图7 全部门店汇总后的商品销量相关性热力图




图 6: 商品相关性热力图，用于展示商品日销量同步波动结构

6.2 同类零食整合

类别聚合按附件 category 字段进行：

$$Y_{t,g} = \sum_{p:c(p)=g} y_{t,p}. \quad (6)$$

该字段具有业务含义，因此作为“同类零食”的正式聚合依据。相关性聚类 and 销量规模分组可作为补充探索，但不替代附件业务类别。




图 7: 类别日销量趋势，用于观察类别层面的时间波动

6.3 类别预测与误差比较

本文比较“单品预测后按类别加总”和“类别聚合后直接预测”。验证结果见表 3。

表 3: 问题二类别预测策略误差比较

方法	模型	MAE	RMSE	WAPE
类别聚合后直接预测	简单指数平滑	7.853	13.933	34.74%
单品预测后按类别加总	简单指数平滑	7.873	13.949	34.83%
类别聚合后直接预测	移动平均 (7 日)	8.246	14.174	36.48%
类别聚合后直接预测	同星期均值 (近 8 周)	8.851	15.057	39.15%




图 8: 类别预测方法 WAPE 对比，用于比较聚合后直接预测和单品预测后加总

因此，问题二主方案采用“附件类别聚合后直接预测 + 简单指数平滑”。相关性聚类 WAPE=31.02%，销量规模分组 WAPE=24.24%，但前者业务类别含义弱，后者预测对象变成高/中/低销量组，均不替代附件类别主方案。

6.4 问题二结果

商品关联分析表明，全部门店汇总层面存在 2 对强正相关商品对和 25 对弱相关商品对。强正相关只能说明历史日销量同步波动，可能共同受客流、消费场景或促销节奏影响，不能证明商品之间存在直接带动关系。负相关候选的相关系数绝对值较小，当前数据未发现强替代关系证据。

类别预测结果显示，未来 7 天预测最高的类别为包装散称，预测 389.613；其次为功能饮料，预测 286.719；碳酸饮料预测 247.326。类别聚合可以降低单品零销量和偶然大单带来的波动，但会损失同一类别内部商品差异。

7 问题三：外部因素统计关联分析

问题三分析天气、节假日、活动日等外部因素与零食销量之间的统计关联。本文将外部因素构造为分类变量和连续变量：天气类型合并为更稳定的天气组，最高温、最低温、平均温度、昼夜温差和风力为连续变量，节假日、周末、活动日为 0-1 变量，星期、月份、门店、商品和历史销量作为控制变量。原始附件中没有湿度字段，因此不构造湿度变量。

7.1 描述性分析

对某一外部因素 G ，先计算不同分组下的平均销量：

$$\bar{y}_g = \frac{1}{n_g} \sum_{i:G_i=g} y_i. \quad (7)$$

该方法直观，但不能控制门店、商品和星期等混杂因素，只作为现象展示。




图 9: 二元外部因素均值差异，用于展示节假日、周末和活动日下的描述性销量差异

7.2 固定效应回归模型

问题三主模型采用“合并天气 + 对数销量 + 历史控制固定效应回归”。设 $z_{s,p,t} = \log(1 + y_{s,p,t})$ ，模型形式为

$$z_{s,p,t} = \beta_0 + \beta^\top External_t + \rho_1 lag7_{s,p,t} + \rho_2 rolling28_{s,p,t} + \gamma_s + \delta_p + \eta_w + \mu_m + \varepsilon_{s,p,t}. \quad (8)$$

其中， $External_t$ 包括合并天气类别、平均温度、昼夜温差、风力、节假日和活动日； γ_s 、 δ_p 、 η_w 、 μ_m 分别表示门店、商品、星期和月份固定效应； lag_7 和 $rolling_28_prev$ 只使用过去销量。线性回归和固定效应思想参考 [5]。

选择该模型的原因是：详细天气类别中存在雨夹雪、暴雨等少数样本天气，直接排序容易不稳；原始销量分布偏斜，对极端销量敏感；加入历史控制项后能减少基础需求差异对外部变量系数的干扰。

方法探索验证指标见表 4。

表 4: 问题三外部因素分析方法验证指标

方法	MAE	RMSE	WAPE	论文定位
原方案详细天气 FE 回归	1.969	4.144	88.09%	补充
合并天气 + 对数销量 + 历史控制 FE 回归	1.890	4.448	84.53%	主分析
温度分箱 + 对数销量 + 历史控制 FE 回归	1.889	4.445	84.51%	非线性检查
去异常日 + 对数销量 + 历史控制 FE 回归	1.825	4.254	84.94%	稳健性检查
随机森林 grouped weather + history	1.892	4.178	84.66%	预测贡献补充




图 10: 回归关联强度排序，用于展示外部变量在控制部分混杂因素后的可比统计关联

7.3 机器学习辅助分析

随机森林置换重要性用于补充判断非线性预测贡献 [1]。它能说明打乱某一特征后预测误差增加多少，但不能说明销量变化方向，也不能证明因果关系。因此，问题三最终结论以回归的统计关联方向为主，以随机森林重要性作为辅助排序依据。




图 11: 随机森林置换重要性，用于展示非线性模型中的预测贡献

7.4 问题三结果

描述性统计显示，不同天气、节假日、周末和活动日下的平均销量存在差异，但这些差异可能与门店、商品、星期和月份同时相关。固定效应回归和稳健性检查表明，活动日变量与销量上升之间的统计关联相对更稳定；天气变量存在一定关联，但细分天气类别受样本量限制；节假日和周末与星期效应、月份季节性重叠，结论应作为辅助。本文不分析湿度，因为附件中没有湿度字段。

8 问题四：综合预测模型与严格递推验证

问题四需要在门店-商品粒度上进行综合预测。设 $y_{s,p,t}$ 表示门店 s 、商品 p 在日期 t 的正向销量，综合模型的特征包括历史销量滞后项、滚动均值、日历变量、门店、商品、类别和外部变量。

8.1 综合模型构造

综合 Ridge 的特征包括滞后销量、滚动均值、星期、月份、是否周末、门店、商品、类别、天气、节假日和活动日。模型可写为

$$\hat{y}_{s,p,t} = f(\text{Lag}_{s,p,t}, \text{Roll}_{s,p,t}, \text{Cal}_t, \text{Store}_s, \text{Product}_p, \text{Category}_p, \text{External}_t). \quad (9)$$

其中, Lag 包括 $\text{lag}_1, \text{lag}_7, \text{lag}_{14}$, Roll 包括 rolling_mean_7 和 rolling_mean_{14} 。Ridge 回归通过 L_2 正则化缓解多重共线性, 适合在保留线性可解释性的同时融合多类特征 [3]。随机森林和其他树模型只作为补充比较, 不作为论文主模型。

8.2 严格 7 日递推验证

信息泄露专项检查 `outputs/q4_information_leakage_review.md` 指出: 原日滚动验证没有当天销量直接进入当天特征, 但验证窗口后续日期的 lag_1 和滚动均值会使用窗口内前几天真实销量。因此, 问题四以 `outputs/q4_recursive_7day_model_comparison.md` 中的严格 7 日递推验证作为主口径。

严格递推验证窗口见表 5。每个窗口只使用窗口起点以前的真实历史销量训练模型; 窗口内第 2 至第 7 天若需要滞后或滚动特征, 则使用前面已经预测出的销量, 而不使用窗口内真实销量。

表 5: 问题四严格 7 日递推验证窗口

窗口起点	窗口终点	长度
2022-03-01	2022-03-07	7
2022-03-08	2022-03-14	7
2022-03-15	2022-03-21	7
2022-03-22	2022-03-28	7

严格递推下, 门店-商品层级误差见表 6。

表 6: 问题四严格 7 日递推主粒度误差比较

模型	MAE	RMSE	WAPE
问题一门店-商品简单指数平滑	1.816	3.772	76.35%
综合 Ridge 回归	1.824	3.702	76.68%
14 日滚动均值基准模型	1.847	3.819	77.66%
7 日移动平均基准模型	1.865	3.797	78.43%
综合随机森林	1.988	4.842	83.60%

在严格 7 日递推验证口径下，综合 Ridge 模型相较部分基准模型仍具有竞争力，但未超过问题一简单指数平滑模型。其主要价值在于统一融合门店、商品、类别、历史销量和外部因素，为多因素解释和情景预测提供一致框架。本文不作全局最优或显著提升的夸大表述。

8.3 未来 7 天预测与整数化

未来 7 天天气、温度、风力和活动日没有附件真实观测，最终预测使用历史同期参考情景；清明节日历按 2022-04-03 至 2022-04-05 为节假日、2022-04-02 为调休上班日处理。因此，最终预测为给定外部变量情景下的条件预测。




图 12: 未来 7 天门店预测总量，用于展示综合模型在门店层面的预测结果




图 13: 未来 7 天类别预测总量，用于展示综合模型在类别层面的预测结果

未来 7 天综合 Ridge 条件预测中，各门店预测总销量最高的是 B 地江山店 321.801，其次为 C 地五乡镇店 279.972 和 A 地天九街店 233.438；各类别预测最高的是包装散称 443.881，其次为功能饮料 374.886 和碳酸饮料 216.494。完整门店-商品-日期小数预测表见 `outputs/final_7day_forecast.csv`。

由于实际销量以件数计，提交展示时对模型预测值进行非负约束和四舍五入整数化处理：预测值小于 0 的先置为 0，其余按四舍五入转为整数；原始小数预测结果仍作为模型连续输出保留。整数化预测表为 `outputs/final_7day_forecast_integer.csv`。小数预测表 7 天预测总量为 1311.294，整数化后 7 天预测总量为 1309。

8.4 误差诊断与情景敏感性

天气敏感性检验 `outputs/q4_weather_sensitivity_report.md` 显示，完整外部变量 Ridge 的严格递推 WAPE 为 76.68%，去除天气变量 Ridge 为 77.73%，历史同期天气情景 Ridge 为 76.57%。因此，天气变量可作为补充情景特征，但不能写成稳定因果因素。

误差诊断 `outputs/q4_error_diagnosis_report.md` 显示，综合 Ridge 在门店 A 地双桥路店、低销量商品和样本不足的活动日场景误差较大；间歇性需求审查 `outputs/intermittent_demand_review.md` 显示，76 条门店-商品序列中有 54 条零销量比例不低于 50%，解释了门店-商品层级 WAPE 较高的原因。间歇性需求建模思想可参考 Croston 方法 [2]，但本文不将其作为主模型。




图 14: 门店误差诊断, 用于定位严格递推验证下误差较高的门店




图 15: 类别误差诊断, 用于定位严格递推验证下误差较高的类别




图 16: 严格递推验证真实值与预测值散点，用于检查预测值与真实值的对应关系

9 模型评价

9.1 误差指标

本文主要采用 MAE、RMSE 和 WAPE 评价预测误差：

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (10)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad (11)$$

$$WAPE = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{\sum_{i=1}^n |y_i|}. \quad (12)$$

MAE 表示平均绝对偏差，便于解释平均误差规模；RMSE 对大误差更敏感，适合检查极端预测偏差；WAPE 用总绝对误差除以总实际销量，适合本题中不同门店和商品销量规模差异较大的情况。对于真实销量为 0 的类别或商品，WAPE 无法定义，需要结合 MAE 和预测合计单独说明。

9.2 分问题评价

问题一中，日滚动验证结果显示，门店层面移动平均 (7 日) $WAPE=37.49\%$ ，商品层面简单指数平滑 $WAPE=38.14\%$ ，门店-商品层面简单指数平滑 $WAPE=74.95\%$ 。补充的 7 日窗口总量验证表明，原问题一主方案在商品层面 $WAPE=21.51\%$ ，门店层面 $WAPE=22.12\%$ ，门店-商品层面 $WAPE=43.06\%$ 。因此，问题一保留简单可解释模型，不引入复杂模型替换主方案。

问题二中，类别聚合后直接预测 + 简单指数平滑的 $WAPE=34.74\%$ ，略优于单品预测后按类别加总的 $WAPE=34.83\%$ 。销量规模分组 $WAPE=24.24\%$ ，相关性聚类 $WAPE=31.02\%$ ，但二者不直接回答“同类零食类别预测”要求，因此只作为补充，不作为主方案。

问题三中，合并天气、对数销量和历史控制固定效应回归的验证 $WAPE=84.53\%$ ，优于原详细天气固定效应回归的 $WAPE=88.09\%$ 。随机森林 grouped weather + history 的 $WAPE=84.66\%$ ，可作为预测贡献补充，但不提供清晰方向，也不能解释因果。问题三主结论应写成“条件统计关联”。

问题四中，严格 7 日递推验证是主评价口径。该口径下，问题一门店-商品简单指数平滑 $WAPE=76.35\%$ ，综合 Ridge $WAPE=76.68\%$ ，14 日滚动均值基准模型 $WAPE=77.66\%$ ，7 日移动平均基准模型 $WAPE=78.43\%$ 。综合 Ridge 优于问题四内部基准模型，但未超过问题一强基准模型。因此，本文仅将其表述为融合前三问信息的解释型综合模型，严格递推误差与强基准模型接近。

9.3 不确定性

不确定性主要来自三类来源。第一，未来天气和活动日采用历史同期情景，若实际天气或促销安排偏离该情景，最终预测会变化。第二，低销量商品和低销量门店存在大量零销量，少量绝对误差即可造成很高 $WAPE$ 。第三，部分稀有天气样本天数较少，例如雨夹雪、暴雨等，不能把其系数作为稳定主结论。

10 优缺点分析与结论

10.1 模型优点

本文模型具有以下优点：

1. 数据口径清晰，区分正向销量、净销量和负向调整。
2. 模型与题目四问一一对应，形成门店、商品、类别和门店-商品的分层预测框架。
3. 主模型优先采用移动平均、同星期均值、指数平滑和固定效应回归，公式简单、可解释、易复现。
4. 对综合模型进行了信息泄露审查，并以严格 7 日递推验证作为主口径。
5. 对外部变量和商品关联均设置了证据边界，没有把相关性写成因果性。

10.2 模型局限

模型局限包括：第一，门店-商品粒度存在大量零销量和间歇性需求，导致 WAPE 较高；第二，未来真实天气和活动安排不可得，含外部变量预测依赖历史同期情景；第三，附件没有顾客购物篮、价格实验、库存和陈列信息，因此无法识别商品互补、替代或促销因果效应；第四，验证期只有有限的完整 7 日窗口，显著性检验和稳定性判断应谨慎。

10.3 结论

本文完成了休闲零食连锁店商品销量预测的四问建模。问题一保留移动平均、同星期均值和简单指数平滑，建立了门店、商品和门店-商品的基础预测；问题二以附件类别字段整合同类零食，商品相关性分析作为同步波动证据，类别预测主方案为类别聚合后直接预测；问题三采用合并天气、对数销量和历史控制固定效应回归，得到外部变量与销量之间的条件统计关联；问题四采用综合 Ridge 模型融合前三问信息，并用严格 7 日递推验证检验未来 7 天预测能力。

最终结论是：简单可解释模型在本题中具有很强竞争力。问题四综合 Ridge 虽然在日滚动一步预测和部分聚合层级上有数值优势，但在严格 7 日递推主粒度下未超过问题一门店-商品简单指数平滑强基准模型。因此，本文不夸大综合模型的预测提升，而将其作为融合历史销量、类别和外部变量的综合解释模型。最终预测表可继续使用 `outputs/final_7day_forecast.csv`，但其含义是给定历史同期天气和活动日情景下的条件预测；整数化提交副本为 `outputs/final_7day_forecast_integer.csv`。

参考文献

- [1] Leo Breiman. Random forests. *Machine Learning*, 45:5–32, 2001.
- [2] J. D. Croston. Forecasting and stock control for intermittent demands. *Operational Research Quarterly*, 23(3):289–303, 1972.
- [3] Arthur E. Hoerl and Robert W. Kennard. Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1):55–67, 1970.
- [4] Rob J. Hyndman and George Athanasopoulos. *Forecasting: Principles and Practice*. OTexts, 3 edition, 2021.
- [5] Douglas C. Montgomery, Elizabeth A. Peck, and G. Geoffrey Vining. *Introduction to Linear Regression Analysis*. Wiley, 5 edition, 2012.

A 附录

A.1 主要代码文件

- 数据读取与清洗: `src/data_loader.py`、`src/preprocessing.py`
- 特征工程: `src/features.py`
- 问题二分析: `src/stage3_q2_analysis.py`
- 问题三分析: `src/stage4_q3_analysis.py`
- 问题四综合模型: `src/stage5_q4_analysis.py`
- 严格递推验证: `src/stage5_q4_recursive_validation.py`
- 问题四误差诊断: `src/stage5_q4_error_diagnosis.py`
- 天气敏感性分析: `src/stage5_q4_weather_sensitivity.py`
- 间歇性需求审查: `src/intermittent_demand_review.py`

A.2 主要结果文件

- 数据检查: `outputs/stage1_data_inspection_report.md`
- 问题一报告: `outputs/stage2_q1_modeling_report.md`
- 问题二报告: `outputs/stage3_q2_relationship_report.md`
- 问题三报告: `outputs/stage4_q3_factor_analysis_report.md`
- 问题四报告: `outputs/stage5_q4_final_model_report.md`
- 信息泄露审查: `outputs/q4_information_leakage_review.md`
- 严格递推验证: `outputs/q4_recursive_7day_model_comparison.md`
- 误差诊断: `outputs/q4_error_diagnosis_report.md`
- 天气敏感性检验: `outputs/q4_weather_sensitivity_report.md`
- 间歇性需求审查: `outputs/intermittent_demand_review.md`
- 最终方法选择: `outputs/method_search/final_method_selection.md`
- 小数预测表: `outputs/final_7day_forecast.csv`
- 整数预测表: `outputs/final_7day_forecast_integer.csv`

A.3 AI 工具使用说明

AI 工具主要用于代码辅助、报告润色、审查提示、格式整理和 LaTeX 排版转换。字段解释、负销量口径、模型取舍、问题四验证口径和最终结论均需团队人工确认。AI 不替代团队对数据、模型和提交材料的最终判断。完整记录见 `outputs/ai_usage_record.md`。